

TEMPLATE PARA ENTREGA DO PROJETO DA DISCIPLINA
Ciência de Dados e Inteligência Artificial
Fase 1

Nome do estudante: Willian Luis Zuqui

Síntese do conjunto de dados como apresentado na sua origem:

Apresente uma breve descrição, acerca do conjunto de dados escolhido, indicando as informações contidas nos dados selecionados. É importante, ao apresentar sua síntese, que você inclua elementos que permitam compreender o significado e a aplicação dos dados escolhidos. (Mínimo de 2 parágrafos)

O conjunto de dados escolhido foi “Cias Abertas: Informação Cadastral”, disponibilizado no “Portal Dados Abertos CVM (Comissão de Valores Mobiliários)”. Segundo a própria origem, a base contém dados cadastrais de companhia abertas, como CNPJ, data de registro e situação do registro. O conjunto disponibiliza informações cadastrais referentes ao último dia útil.

A base foi escolhida por permitir a análise de características cadastrais de empresas reguladas pela CVM, como setor de atividade, categoria de registro, situação cadastral, controle acionário e localização. Essas informações podem apoiar estudos de ciência de dados voltados à identificação de padrões entre empresas ativas, canceladas ou suspensas, usando a coluna “SIT” (Situação do registro) como atributo alvo.

Quantidade de linhas e colunas do conjunto de dados:

Descreva apenas a quantidade de linhas e de colunas selecionadas.

O conjunto de dados preparado para a fase 1 possui 1.432 linhas e 12 colunas.

Escolha pelo menos 10 colunas totalmente preenchidas (as mais importantes) e, para cada coluna (inclusive para a coluna alvo):

- Qual o nome e o que representa?
- Qual o tipo de dados? Nominal/Ordinal/Numérico/Data e/ou hora?
- Quais são os valores considerados válidos?
- Quantos valores distintos aparecem na coluna?
- Qual o menor e o maior valor, e qual a moda?
- Os valores da coluna são numéricos? Qual a média e qual o desvio-padrão? Qual a mediana?

Você pode apresentar essas informações da maneira como entender mais conveniente, como por exemplo em uma tabela, parágrafos, etc. É importante que sejam inseridas as imagens e as evidências do passo a passo realizado na atividade.

ATENÇÃO: Apresente imagens evidenciando os cálculos (Ex: print das fórmulas do Excel, Orange, script em python, etc). Os trabalhos que não apresentarem imagens receberam um desconto na nota.

- 1) SIT (coluna alvo):
 - Representa: Situação cadastral da companhia
 - Tipo: Categórico
 - Valores válidos: ATIVO, CANCELADA, SUSPENSO(A) - DECISÃO ADM
- 2) CNPJ_CIA:
 - Representa: CNPJ da companhia
 - Tipo: Nominal
 - Valores válidos: CNPJ válido no formato 00.000.000/0000-00
 - Valores distintos: 1316
- 3) DEMON_SOCIAL:
 - Representa: Razão social da companhia
 - Tipo: Nominal
 - Valores válidos: Texto
 - Valores distintos: 1316
- 4) MUN:
 - Representa: Município da sede da companhia
 - Tipo: Nominal
 - Valores válidos: Texto
 - Valores distintos: 208
- 5) CD_CVM:
 - Representa: Código de identificação da CVM
 - Tipo: Numérico
 - Valores válidos: Número inteiro positivo
 - Valores distintos: 1321
- 6) DT_REG:
 - Representa: Data registro da companhia na CVM
 - Tipo: Data/hora
 - Valores válidos: Datas válidas
 - Valores distintos: 1071
 - Menor: 1932-12-28, Maior: 2026-06-07, Moda: 1977-07-20, Mediana: 2007-10-10
- 7) DT_INI_SIT:
 - Representa: Data de início da situação cadastral atual
 - Tipo: Data/hora
 - Valores válidos: Datas válidas
 - Valores distintos: 996
 - Menor: 1938-04-19, Maior: 2026-05-19, Moda: 2010-01-04, Mediana: 2016-01-07
- 8) SETOR_ATIV:
 - Representa: Setor de atividade da companhia
 - Tipo: Categórico
 - Valores válidos: Setores econômicos informados pela CVM
 - Valores distintos: 65
- 9) CONTROLE_ACIONARIO:
 - Representa: Tipo de controle acionário
 - Tipo: Categórico
 - Valores válidos: ESTATAL, ESTATAL HOLDING, ESTRANGEIRO, ESTRANGEIRO HOLDING, PRIVADO, PRIVADO HOLDING
 - Valores distintos: 6

10) TP_ENDER:

- Representa: Tipo de endereço cadastrado
- Tipo: Categórico
- Valores válidos: SEDE
- Valores distintos: 1

11) UF:

- Representa: Unidade federativa da sede
- Tipo: Nominal
- Valores válidos: Siglas de UF brasileiros
- Valores distintos: 24

12) CATEG_REG:

- Representa: Categoria de registro da companhia na CVM
- Tipo: Categórico
- Valores válidos: Categoria A, Categoria B




Figura 1. Fluxo montado no Orange para importação, seleção, filtragem, estatísticas, visualização e salvamento do conjunto de dados




Figura 2. Informações gerais do conjunto de dados selecionado




Figura 3. Seleção das colunas utilizadas e definição da coluna alvo SIT




Figura 4. Filtros aplicados para remover registros com valores faltantes nas colunas escolhidas




Figura 5. Estatísticas das colunas selecionadas, evidenciando ausência de valores faltantes

SIT	CNPJ_CIA	DENOM_SOCIAL	MUN	CD_CVM	DT_REG	DT_MIS	SETOR_ATIV	CONTROLE_AC	TP_ENDER	UF	CATEG_REG	SIT
SUSPENSÃO	08.773.133/0001	ZW ECOBANK S.	SÃO PAULO	2524	2005-10-29 00:00	2005-05-19 00:00	Energia Elétrica	PRIVADO	SEDE	SP	Categoria A	SUSPENSÃO
CANCELADA	11.386.033/0001	3A COMPANHIA	RIO DE JANEIRO	2194	2002-05-08 00:00	2002-12-13 00:00	Segurização d.	PRIVADO	SEDE	RJ	Categoria B	CANCELADA
ATIVO	01.547.740/0001	S21 PARTICIPA.	RIO DE JANEIRO	16330	1997-07-11 00:00	1997-07-11 00:00	Emp. Adm. Part.	PRIVADO	SEDE	RJ	Categoria B	ATIVO
ATIVO	01.851.771/0001	S24 PARTICIPA.	RIO DE JANEIRO	16284	1997-05-30 00:00	1997-05-30 00:00	Emp. Adm. Part.	PRIVADO	SEDE	RJ	Categoria A	ATIVO
CANCELADA	34.033.779/0001	ABR AMBRO AR.	BARUERI	15270	1992-12-20 00:00	2009-09-29 00:00	Anedamento	PRIVADO	SEDE	SP	Categoria A	CANCELADA
CANCELADA	07.794.251/0001	ABRADA PLAL	SÃO PAULO	20206	2006-05-24 00:00	2006-05-24 00:00	Emp. Adm. Part.	PRIVADO	SEDE	SP	Categoria A	CANCELADA
ATIVO	07.636.657/0001	ACD VERDE DO.	ACAI ANDIA	16429	2021-11-29 00:00	2021-11-29 00:00	Metallurgia e S.	PRIVADO	SEDE	MA	Categoria B	ATIVO
CANCELADA	60.664.810/0001	ACOS VILLARE.	SÃO PAULO	108	1995-05-16 00:00	2005-12-30 00:00	Metallurgia e S.	PRIVADO	SEDE	SP	Categoria A	CANCELADA
CANCELADA	07.825.881/0001	ACRUX SECUR.	RIO DE JANEIRO	20700	2008-06-28 00:00	2008-06-28 00:00	Segurização d.	PRIVADO	SEDE	RJ	Categoria B	CANCELADA
CANCELADA	47.080.819/0001	ACUAR GUAR.	OLIMPIA	20440	2002-05-20 00:00	2002-05-20 00:00	Agricultura (Ag.	PRIVADO HOLDING	SEDE	SP	Categoria A	CANCELADA
CANCELADA	10.345.009/0001	ADVANCED DL.	SÃO PAULO	17723	2002-08-24 00:00	2002-07-12 00:00	Farmacêutico e.	PRIVADO	SEDE	SP	Categoria A	CANCELADA
ATIVO	08.827.501/0001	AEGEA SANE.	SÃO PAULO	23396	2014-05-21 00:00	2014-05-21 00:00	Saneamento, S.	PRIVADO HOLDING	SEDE	SP	Categoria A	ATIVO
ATIVO	12.528.708/0001	AERIS IND. E C.	CAUCAIA	12471	2009-11-09 00:00	2009-11-09 00:00	Máquinas, Equi.	PRIVADO	SEDE	CE	Categoria A	ATIVO
ATIVO	12.528.708/0001	AERIS IND. E C.	CAUCAIA	12471	2009-11-09 00:00	2009-11-09 00:00	Máquinas, Equi.	PRIVADO	SEDE	CE	Categoria A	ATIVO
CANCELADA	01.917.705/0001	AES ELPA SA	BARUERI	19313	2002-10-14 00:00	2002-09-05 00:00	Emp. Adm. Part.	PRIVADO HOLDING	SEDE	SP	Categoria A	CANCELADA
CANCELADA	04.128.563/0001	AES TIET ENER.	SÃO PAULO	18970	2001-08-29 00:00	2001-09-13 00:00	Emp. Adm. Part.	PRIVADO	SEDE	SP	Categoria A	CANCELADA
CANCELADA	04.128.563/0001	AES TIET ENER.	SÃO PAULO	18970	2001-08-29 00:00	2001-09-13 00:00	Emp. Adm. Part.	PRIVADO	SEDE	SP	Categoria A	CANCELADA
CANCELADA	02.998.609/0001	AES TIET SA	BARUERI	18350	1999-07-14 00:00	2001-10-26 00:00	Energia Elétrica	PRIVADO	SEDE	SP	Categoria A	CANCELADA
CANCELADA	02.998.609/0001	AES TIET SA	BARUERI	18350	1999-07-14 00:00	2001-10-26 00:00	Energia Elétrica	PRIVADO	SEDE	SP	Categoria A	CANCELADA
CANCELADA	02.008.481/0001	ATETIS SECUR.	SÃO PAULO	18104	1998-12-17 00:00	2001-06-24 00:00	Segurização d.	PRIVADO HOLDING	SEDE	SP	Categoria B	CANCELADA
CANCELADA	07.620.094/0001	ARJUNTE GER.	SÃO PAULO	21052	2008-04-17 00:00	2001-10-24 00:00	Energia Elétrica	PRIVADO	SEDE	SP	Categoria A	CANCELADA
ATIVO	16.338.320/0001	ARJUNTE TRAL	RIO DE JANEIRO	21179	2010-05-24 00:00	2010-05-24 00:00	Energia Elétrica	PRIVADO HOLDING	SEDE	RJ	Categoria A	ATIVO
CANCELADA	07.696.047/0001	AGRA EMPREE.	SÃO PAULO	26664	2007-04-19 00:00	2005-05-28 00:00	Construção Civ.	PRIVADO	SEDE	SP	Categoria A	CANCELADA
CANCELADA	11.040.082/0001	AGRE EMPREE.	SÃO PAULO	19111	2009-12-22 00:00	2005-07-19 00:00	Construção Civ.	PRIVADO	SEDE	SP	Categoria A	CANCELADA
ATIVO	21.240.140/0001	AGROGALAXY	GOIÂNIA	25658	2001-08-19 00:00	2001-08-19 00:00	Comércio (Alac.	PRIVADO	SEDE	GO	Categoria A	ATIVO
ATIVO	21.157.474/0001	ÁGUAS DE TER.	TERESINA	14617	2011-02-25 00:00	2011-02-25 00:00	Saneamento, S.	PRIVADO	SEDE	PI	Categoria B	ATIVO
ATIVO	61.067.901/0001	ÁGUAS DO PAR.	BELEM	27978	2006-01-15 00:00	2006-01-15 00:00	Saneamento, S.	PRIVADO	SEDE	PA	Categoria B	ATIVO
ATIVO	61.067.902/0001	ÁGUAS DO PAR.	BRAGANÇA	27960	2006-01-15 00:00	2006-01-15 00:00	Saneamento, S.	PRIVADO	SEDE	PA	Categoria B	ATIVO
ATIVO	61.067.904/0001	ÁGUAS DO PAR.	PARAIPUEBAS	27981	2006-01-15 00:00	2006-01-15 00:00	Saneamento, S.	PRIVADO	SEDE	PA	Categoria B	ATIVO
ATIVO	42.310.775/0001	ÁGUAS DO RIO.	RIO DE JANEIRO	26725	2002-02-20 00:00	2002-02-20 00:00	Saneamento, S.	PRIVADO	SEDE	RJ	Categoria B	ATIVO
ATIVO	42.644.220/0001	ÁGUAS DO RIO.	RIO DE JANEIRO	26743	2002-02-30 00:00	2002-02-30 00:00	Saneamento, S.	PRIVADO	SEDE	RJ	Categoria B	ATIVO
ATIVO	43.646.117/0001	ÁGUAS DO SER.	PENEDO	27359	2003-11-03 00:00	2003-11-03 00:00	Saneamento, S.	PRIVADO HOLDING	SEDE	AL	Categoria B	ATIVO
ATIVO	04.093.570/0001	ÁGUAS GUAR.	CAMPO GRANDE	23442	2014-08-06 00:00	2014-08-06 00:00	Saneamento, S.	PRIVADO	SEDE	MS	Categoria B	ATIVO
CANCELADA	09.594.766/0001	AGI HOLDING	VIMEDO	18386	2009-11-05 00:00	2004-02-10 00:00	Emp. Adm. Part.	PRIVADO	SEDE	SP	Categoria B	CANCELADA
CANCELADA	23.438.929/0001	ALARES INTER.	SÃO PAULO	25194	2005-10-14 00:00	2005-10-14 00:00	Emp. Adm. Part.	PRIVADO	SEDE	SP	Categoria A	CANCELADA
CANCELADA	08.240.673/0001	ALCALUI G.	MACAU	15067	1995-03-28 00:00	2000-01-04 00:00	Petroquímicos	PRIVADO	SEDE	RN	Categoria A	CANCELADA
ATIVO	17.167.896/0001	ALFA HOLDING	SÃO PAULO	9954	1975-02-20 00:00	1975-02-20 00:00	Emp. Adm. Part.	PRIVADO HOLDING	SEDE	SP	Categoria B	ATIVO
ATIVO	71.285.116/0001	ALGAR TELECO.	UBERLÂNDIA	15052	2007-07-27 00:00	2007-07-27 00:00	Telecomunicações	PRIVADO	SEDE	MG	Categoria B	ATIVO
CANCELADA	06.082.980/0001	ALIANCIE SHO.	RIO DE JANEIRO	21300	2008-01-18 00:00	2008-08-05 00:00	Emp. Adm. Part.	PRIVADO	SEDE	RJ	Categoria A	CANCELADA
CANCELADA	61.156.931/0001	ALPERTI S.A.	SÃO PAULO	12821	1998-06-06 00:00	1998-06-06 00:00	Emp. Adm. Part.	PRIVADO	SEDE	SP	Categoria A	CANCELADA
CANCELADA	02.783.423/0001	ALORA PARTICIP.	RIO DE JANEIRO	16082	1998-02-10 00:00	2001-08-21 00:00	Emp. Adm. Part.	PRIVADO	SEDE	RJ	Categoria A	CANCELADA
ATIVO	42.771.940/0001	ALIANÇA SAUL	SÃO PAULO	14059	2016-10-26 00:00	2016-10-26 00:00	Serviços Médicos	PRIVADO	SEDE	SP	Categoria A	ATIVO
ATIVO	20.247.322/0001	ALLIED TECNO.	SÃO PAULO	25330	2002-11-25 00:00	2002-11-25 00:00	Comércio (Alac.	PRIVADO	SEDE	SP	Categoria A	ATIVO
CANCELADA	08.648.295/0001	ALLOS PARTICIP.	SÃO PAULO	25330	2002-11-25 00:00	2002-11-25 00:00	Comércio (Alac.	PRIVADO	SEDE	SP	Categoria A	CANCELADA
ATIVO	05.878.397/0001	ALLOS S.A.	RIO DE JANEIRO	25337	2001-02-01 00:00	2001-02-01 00:00	Emp. Adm. Part.	PRIVADO HOLDING	SEDE	RJ	Categoria A	ATIVO
ATIVO	05.878.397/0001	ALLOS S.A.	RIO DE JANEIRO	25337	2001-02-01 00:00	2001-02-01 00:00	Emp. Adm. Part.	PRIVADO HOLDING	SEDE	RJ	Categoria A	ATIVO
ATIVO	60.537.263/0001	ALPARK EMPR.	SÃO PAULO	24951	2002-05-13 00:00	2002-05-13 00:00	Serviços Transp.	PRIVADO	SEDE	SP	Categoria A	ATIVO
ATIVO	60.537.263/0001	ALPARK EMPR.	SÃO PAULO	24951	2002-05-13 00:00	2002-05-13 00:00	Serviços Transp.	PRIVADO	SEDE	SP	Categoria A	ATIVO
ATIVO	61.126.676/0001	ALMEIDA SAUL	SÃO PAULO	16337	2011-11-22 00:00	2011-11-22 00:00	Emp. Adm. Part.	PRIVADO	SEDE	SP	Categoria A	ATIVO
ATIVO	61.079.117/0001	ALFARGATAS SA	SÃO PAULO	10456	1977-07-20 00:00	1977-07-20 00:00	Têxtil e Vestuário	PRIVADO	SEDE	SP	Categoria A	ATIVO
ATIVO	61.079.117/0001	ALFARGATAS SA	SÃO PAULO	10456	1977-07-20 00:00	1977-07-20 00:00	Têxtil e Vestuário	PRIVADO	SEDE	SP	Categoria A	ATIVO
CANCELADA	11.721.821/0001	ALPER CONSUM.	SÃO PAULO	12317	2002-02-18 00:00	2002-02-18 00:00	Emp. Adm. Part.	PRIVADO	SEDE	SP	Categoria A	CANCELADA
ATIVO	16.811.031/0001	ALPHAVILLE S.A.	SÃO PAULO	25275	2002-11-05 00:00	2002-11-05 00:00	Construção Civ.	PRIVADO	SEDE	SP	Categoria A	ATIVO
CANCELADA	02.783.423/0001	ALTRE SECUR.	SÃO PAULO	18066	1998-11-10 00:00	2004-08-09 00:00	Segurização d.	PRIVADO HOLDING	SEDE	SP	Categoria B	CANCELADA
ATIVO	48.344.725/0001	ALTHAIA S.A. L.	ATIBAIA	27029	2002-11-30 00:00	2002-11-30 00:00	Farmacêutico e.	PRIVADO	SEDE	SP	Categoria B	ATIVO

Figura 6. Visualização final do conjunto de dados preparado

Descrição da coluna alvo e potenciais aplicações:

Informe qual a coluna alvo escolhida e descreva possíveis aplicações usando aprendizado de máquina que possam utilizá-la.

A coluna alvo escolhida foi SIT, que representa a situação cadastral da companhia aberta perante a CVM. No conjunto de dados selecionado, essa coluna possui três classes: ATIVO, CANCELADA e SUSPENSO(A) - DECISÃO ADM. Por ser uma variável categórica, ela pode ser utilizada em um problema de classificação supervisionada.

O interesse inicial deste projeto surgiu da área de análise de crédito empresarial, especialmente da ideia de avaliar se um futuro cliente poderia representar menor ou maior risco para concessão de crédito. Em análises de crédito, é comum observar aspectos próximos aos 5Cs de crédito, como caráter/reputação, capacidade de pagamento, capital, garantias e condições externas. Como não foi encontrada uma base pública brasileira simples com empresas rotuladas diretamente como “bom pagador” ou “mau pagador”, este trabalho utiliza dados públicos cadastrais da CVM como uma primeira etapa de análise do perfil das empresas.

Como aplicação futura, modelos de aprendizado de máquina como Árvore de Decisão, Random Forest e Regressão Logística poderiam ser treinados no Orange para classificar empresas conforme a situação cadastral, permitindo comparar quais atributos possuem maior relação com a situação da companhia.

Link para acesso aos dados selecionados:

Inclua aqui o link para o conjunto de dados escolhido. No caso de ter sido feito um recorte/amostragem do conjunto original, documentar quais foram os passos feitos para produzir o recorte.

ATENÇÃO: O conjunto de dados do link deve estar PRONTO para ser carregado no Orange.

Fonte original dos dados:

https://dados.cvm.gov.br/dataset/cia_aberta-cad

https://dados.cvm.gov.br/dados/CIA_ABERTA/CAD/DADOS/cad_cia_aberta.csv

Vou deixar os arquivos no meu github, tanto o arquivo de recorte quando o arquivo do Orange:

<https://github.com/wzuqui/pucrs-ciencia-dados-inteligencia-artificial-projeto>