

TEMPLATE PARA ENTREGA DO PROJETO DA DISCIPLINA
Ciência de Dados e Inteligência Artificial
Fase 2

Nome do estudante: Willian Luis Zuqui

Desenvolva um processo de ciência de dados no Orange Data Mining, cobrindo os elementos abaixo.
Para cada um dos itens solicitados é necessário inserir imagens que evidenciem o trabalho realizado.

Exploração dos dados:

Que tipo de experimentos você fez na exploração dos dados (verificação de outliers, cálculos de médias, dados inválidos etc.).

O conjunto de dados utilizado foi o cadastro de companhias abertas da CVM (arquivos cad_cia_aberta.csv) com 2.673 registros e 47 colunas originais. A exploração foi realizada no Orange com os widgets CSV File Import, Data Table, Feature Statistics e Data Info.

As principais verificações e achados foram:

- **Valores faltantes:** as colunas selecionadas para o estudo não apresentaram valores ausentes (no missing data).
- **Variável-alvo (SIT situação do registro):** possui três valores (ATIVO, CANCELADA E SUSPENSO).
- **Registros duplicados:** no Data Table observei empresas repetidas (exemplo AERIS, AES TIETE SA, ALLOS). A CVM lista a mesma empresa uma vez por tipo de mercado (TP_MERC = BOLSA, BALCÃO ORGANIZADO), gerando 147 linha duplicadas, na prática 2.526 empresas distintas.
- **Colunas problemáticas:** CEP e CD_CVM são identificadores, a DT_INI_SIT é a data de início da situação atual e, para empresas canceladas, equivale à data do cancelamento, configurando assim vazamento de informação (data leakage).
- **Distribuição do alvo:** após a limpeza, o problema mostrou-se desbalanceado, cerca de 74% CANCELADA e 26% ATIVO.




Figura 1 – Dados originais do cad_cia_aberta.csv.



Figura 2 - Coluna "Missing" em 0%, confirmando a ausência de valores faltantes. Variável alvo SIT possuindo três valores.

The screenshot shows the 'Data Table' widget in Orange. It displays a dataset with columns: SIT, CNPJ, DENOM, SOCIAL, MUN, CEP, CD, CVM, DT, REG, DT, INI, SIT, SETOR, ATIV, ATROLE, AÇONA, TP, ENDER, UF. The 'SIT' column has values 'ATIVO' and 'CANCELADA'. The 'DENOM, SOCIAL' column contains company names. The 'MUN' column shows cities. The 'CEP' column shows postal codes. The 'CD, CVM' column shows stock codes. The 'DT, REG' column shows registration dates. The 'DT, INI, SIT' column shows start dates and status. The 'SETOR, ATIV' column shows sectors and activities. The 'ATROLE, AÇONA' column shows control and ownership. The 'TP, ENDER' column shows type and address. The 'UF' column shows the state. The table is sorted by 'SIT' and 'CNPJ'. Several rows are selected, highlighting companies like AERIS IND. E COM. DE EQUIP. PARA GER. DE ENG. S.A. and AERIS IND. E COM. DE EQUIP. PARA GER. DE ENG. S.A.

Figura 3 - Data Table com as linhas selecionadas mostrando empresas repetidas.

The screenshot shows the 'Confusion Matrix' widget in Orange. It displays a confusion matrix for the 'Logistic Regression' model. The matrix shows the relationship between actual and predicted values for 'ATIVO' and 'CANCELADA' status. The matrix is as follows:

		Predicted		Σ
		ATIVO	CANCELADA	
Actual	ATIVO	239	411	650
	CANCELADA	126	1733	1859
Σ		365	2144	2509

The widget also shows the 'Learners' list with 'Logistic Regression' selected. The 'Output' section has 'Predictions' checked. The 'Apply Automatically' checkbox is also checked. The 'Show' dropdown is set to 'Number of instances'.

Figura 4 - Matriz de Confusão evidenciando desbalanceamento sendo 74% CANCELADA E 26% ATIVO.

Escolha de, ao menos, três algoritmos de aprendizado para a modelagem:

Apresente os algoritmos utilizados e justifique a escolha.

Foram escolhidos três algoritmos de classificação supervisionada de famílias diferentes para permitir comparação:

- **Árvore de decisão (Tree):** modelo interpretável, que gera regras de decisão e lida naturalmente com atributos categóricos.

- **Random Forest:** conjunto (ensemble) de várias árvores, tende a ser mais robusto e a reduzir o overfitting de uma única árvore.
- **Regressão Logística (Logistic Regression):** modelo linear e probabilístico, que fornece a probabilidade de uma empresa pertencer à classe de risco, característica desejável para um analisador de risco.

A escolha privilegia a diversidade de abordagens, um modelo linear frente a dois baseados em árvores, permitindo comparar famílias distintas de algoritmos no mesmo problema, majoritariamente categórico. Os três modelos foram conectados ao widget *Test and Score* (entrada *Learner*) conforme a figura abaixo.




Figura 5 - Os três algoritmos (*Tree*, *Random Forest* e *Logistic Regression*) conectados ao widget *Test and Score*.

Preparação dos dados de acordo com as características dos algoritmos de aprendizado escolhidos:

Descreva o processo realizado para essa etapa.

A preparação foi conduzida levando em conta as exigências de cada algoritmo:

- **Alvo binário:** a coluna SIT foi reduzida a duas classes (ATIVO E CANCELADA), descartando os poucos casos SUSPENSO.
- **Remoção de duplicadas:** com o widget *Group By* agrupei com CNPJ_CIA mantendo uma linha por empresa, reduzindo de 2.655 para 2.509 linhas. Isso elimina o vazamento entre treino e teste.
- **Seleção de atributos:** mantidas como features SETOR_ATIVO, CONTROLE_ACIONARIO e UF movidos para metadados os identificadores (CNPJ_CIA, DENOM_SOCIAL, MUN) e removidos CEP, CD_CVM (ruído) e DT_INI_SIT (vazamento).
- **Ajustes pós Group By:** usei o *Edit Domain* para restaurar os nomes das colunas e o *Select Columns* para redefinir os papéis (alvo, features e metadados).
- **Continue (preparação específica por algoritmo):** a árvore falhava com SETOR_ATIVO (mais de 16 categorias) e a regressão logística exige variáveis numéricas. Apliquei esse widget com *One-hot encoding*, onde cada linha recebe o valor 1 na coluna da sua respectiva categoria e 0 em todas as outras.
- **Variável de data:** a DT_REG foi ignorada, pois variáveis de data exigem conversão ou normalização específica.




Figura 6 - Filtro da coluna SIT ou alvo binário.




Figura 7 – Group By, agrupado por CNPJ_CIA mantendo somente o primeiro registro.




Figura 8 - Seleção de features, mantendo somente dados importantes para o treinamento.




Figura 9 - Edit Domain com restauração dos nomes das colunas.




Figura 10 - Select Columns para redefinir os papéis como alvo, features e metadados.




Figura 11 - Continuize configurado com as variáveis utilizando o One-hot encoding.




Figura 12 - Orange completo do projeto (fase-2.ows) da leitura do CSV até o Test and Score, Confusion Matrix e ROC.

Execução dos experimentos de aprendizado e coleta das métricas:

Descreva o processo e os resultados obtidos.

Os experimentos foram executados com o widget *Test and Score*, usando validação cruzada estratificada de 10 dobras (10-fold). Os três modelos foram avaliados sobre a mesma base preparada.

Modelo	AUC	CA	F1	Precisão	Recall	MCC
Árvore de Decisão	0,751	0,752	0,836	0,818	0,855	0,327
Regressão Logística	0,790	0,786	0,866	0,808	0,932	0,373
Random Forest	0,774	0,772	0,816	0,816	0,895	0,355

Figura 13 - Resultados (média sobre as classes)

Pela classe de risco (CANCELADA), o recall, proporção de empresas canceladas corretamente identificadas, foi de 0,932 (Regressão Logística), 0,895 (Random Forest) e 0,855 (Árvore de Decisão).




Figura 14 - widget Test and Score (Cross validation 10-folds) com as métricas dos três modelos.

Modelo	ATIVO → ATIVO	ATIVO → CANCELADA	CANCELADA → ATIVO	CANCELADA → CANCELADA
Árvore de Decisão	297	353	270	1.589
Regressão Logística	239	411	126	1.733
Randon Forest	274	376	196	1.663

Figura 15 - Matrices de confusão (número de instâncias, classes ATIVO ou CANCELADA).




Figura 16 - Confusion Matrix Tree.




Figura 17 - Confusion Matrix Logistic Regression.




Figura 18 - Confusion Matrix Random Forest.




Figura 19 - ROC Analysis: curvas dos três modelos para a classe CANCELADA.

Relato dos experimentos e lições aprendidas:

Apresente uma reflexão acerca dos resultados obtidos com este projeto.

Todos os modelos superaram a linha de base de 74% (acurácia de um classificador que sempre prevê a classe majoritária, CANCELADA), o que indica que efetivamente aprenderam padrões.

A regressão Logística obteve o melhor desempenho geral (AUC 0,790 e o maior MCC) e o maior recall na classe de risco (0,932). Como o objetivo é um analisador de risco conservador, esse é o modelo mais adequado: prioriza não deixar passar uma empresa que encerrará as atividades. O custo é um número maior de falsos positivos (precisão de 0,808 na classe CANCELADA), trade-off aceitável quando o erro mais caro é liberar uma empresa que vai quebrar.

Lições aprendidas:

- Em bases desbalanceadas, a acurácia isolada engana, AUC, F1, recall e matriz de confusão dão um retrato mais honesto.
- Duplicatas podem estar escondidas e causar vazamento entre treino e teste, daí a importância da exploração antes de modelar.
- É preciso evitar o vazamento de variáveis que codificam a resposta como no caso do DT_INI_SIT.
- A preparação dos dados depende do algoritmo, a árvore lidou mal com categóricas de alta cardinalidade e o modelo linear exigiu Continuize.
- Limitação: foram usadas apenas três variáveis cadastrais. Indicadores financeiros, como DFP da CVM, poderiam enriquecer o modelo em trabalhos futuros.

Link para o arquivo do projeto do Orange e dos dados utilizados:

Insira os links para os arquivos.

Vou deixar os arquivos no meu github, tanto o arquivo de recorte quando o arquivo do Orange:

<https://github.com/wzuqui/pucrs-ciencia-dados-inteligencia-artificial-projeto>